

Pontificia Universidad Católica de Chile
Instituto de Ingeniería Matemática y Computacional
Álgebra Lineal Avanzada y Modelamiento — IMT2230

Proyecto 2: PageRank sobre redes reales

Red elegida: Twitter (ICWSM) — munmun_twitter_social (KONECT)

1. Red elegida y estadísticas básicas

La red seleccionada corresponde al conjunto de datos `munmun_twitter_social`, disponible en KONECT (http://konect.cc/networks/munmun_twitter_social/), construido a partir de datos usados en el estudio de dinámicas de conversación en Twitter presentado en ICWSM 2010. Los nodos representan cuentas de usuario de Twitter, y una arista dirigida $i \rightarrow j$ indica que el usuario i sigue (*follow*) al usuario j . Es, por lo tanto, una red social dirigida de tipo “quién sigue a quién”, con un contexto claramente interpretable: el grado de entrada de un nodo refleja cuántos usuarios lo siguen (popularidad/influencia potencial), mientras que el grado de salida refleja cuántas cuentas sigue ese usuario.

Se eligió esta red porque supera ampliamente los mínimos exigidos (500 nodos, 2000 aristas), tiene una interpretación directa en términos de influencia social, y es un caso clásico para poner a prueba PageRank frente a una métrica simple como el grado de entrada, dado que en redes de seguidores existen usuarios con muchos seguidores pero de baja calidad estructural, y usuarios con pocos seguidores pero estratégicamente conectados.

Estadística	Valor
n (nodos)	465 017
m (aristas)	834 797
Grado de entrada medio $\bar{d}^{\text{in}}$	1.7952
Grado de salida medio $\bar{d}^{\text{out}}$	1.7952
Nodo de mayor grado de entrada	643 (in-degree = 199)
Densidad $m/(n(n-1))$	3.8605×10^{-6}
Nodos colgantes (out-degree = 0)	462 515 (99.46 %)

Table 1: Estadísticas básicas de la red `munmun_twitter_social`.

2. Pregunta e hipótesis inicial

Pregunta: “¿Qué usuarios de Twitter concentran mayor influencia dentro de esta red de seguimiento (*follow*), y esa influencia coincide simplemente con tener muchos seguidores, o depende también de quién te sigue?”

Hipótesis inicial: dado que en Twitter la relación “seguir” no es recíproca y la popularidad suele concentrarse en pocos nodos, se espera que los usuarios con mayor grado de entrada (más seguidores)

tiendan a tener mayor PageRank, pero que la correlación no sea perfecta: cuentas seguidas por pocos usuarios pero muy influyentes deberían tener un PageRank desproporcionadamente alto respecto a su in-degree, mientras que cuentas con muchos seguidores “de bajo perfil” deberían quedar relativamente más abajo de lo que su in-degree sugiere. Además, dado que el 99.46 % de los nodos son colgantes, se anticipa que el término de teletransportación de la Matriz de Google jugará un rol dominante en el resultado final, comprimiendo buena parte de las diferencias de PageRank entre los usuarios.

3. Análisis exploratorio de la red

(a) Distribución de grados

Las distribuciones de grado de entrada y de salida (en escala log-log, Figura 1) muestran el comportamiento típico de una red social de tipo “libre de escala”: la gran mayoría de los usuarios tiene un grado de entrada muy bajo (1 o 2), mientras que unos pocos nodos concentran grados de entrada de hasta 199. La distribución de grado de salida es notablemente distinta: se observa un límite artificial en 500 (posiblemente un tope impuesto por la plataforma o el proceso de recolección de datos), con un grupo importante de usuarios exactamente en ese límite.




Figure 1: Distribución de grado de entrada (izquierda) y de grado de salida (derecha), escala log-log.

(b) Nodos colgantes

Se identificaron 462 515 nodos colgantes (out-degree = 0), correspondiente al **99.46 %** de la red: prácticamente todos los usuarios de esta muestra no siguen a nadie dentro del conjunto de datos. Esto es problemático para PageRank porque cada columna de H asociada a un nodo colgante queda completamente en cero, de modo que H deja de ser columna-estocástica: la masa de probabilidad de la caminata aleatoria se “pierde” cada vez que el paseante cae en uno de estos nodos. Esto se corrige construyendo la matriz S , donde cada columna cero de H se reemplaza por el vector uniforme $\mathbf{1}/n$, interpretando que un usuario colgante “salta” a cualquier otro usuario con igual probabilidad, restaurando la propiedad de columna-estocástica necesaria para que la cadena de Markov esté bien definida.

(c) Top-10 nodos por grado de entrada y de salida

Rango	Nodo (ID)	In-degree
1	643	199
2	1405	174
3	5486	174
4	1379	161
5	1471	153
6	2748	151
7	2467	150
8	612	144
9	14047	139
10	5449	133

Table 2: Top-10 por grado de entrada.

Rango	Nodo (ID)	Out-degree
1	3418	500
2	5656	500
3	6389	500
4	6595	500
5	6667	500
6	6699	500
7	7780	500
8	8649	500
9	8808	500
10	8828	500

Table 3: Top-10 por grado de salida (nótese el tope en 500).

(d) Conectividad de la red

Se calcularon las componentes fuertemente conexas del grafo, encontrándose 463 245 componentes, con la componente más grande de solo 1 726 nodos (0.37 % de la red total). Esto confirma que la red **no** es fuertemente conexa, lo cual es esperable en redes sociales grandes de este tipo, dominadas por nodos colgantes y estructuras en forma de “estrella”. A pesar de esto, la Matriz de Google G construida en la Sección 4 es siempre irreducible y aperiódica gracias al término de teletransportación $\frac{1-\alpha}{n}\mathbf{1}\mathbf{1}^T$, que garantiza que exista una probabilidad positiva de ir de cualquier nodo a cualquier otro en un solo paso, sin importar la estructura real (posiblemente desconectada) del grafo subyacente.

4. Construcción de la Matriz de Google

(a) Matriz de hipervínculos H

La matriz H se construyó en formato disperso (`scipy.sparse`, CSC) con

$$H_{ij} = \begin{cases} 1/\text{out}(j) & \text{si } j \rightarrow i \\ 0 & \text{si no,} \end{cases}$$

Dado que $n \approx 465\,017$, una matriz densa $n \times n$ sería intratable ($\approx 2.16 \times 10^{11}$ entradas), por lo que trabajar en formato disperso es indispensable. Cada columna de H correspondiente a un nodo fuente j con $\text{out}(j) > 0$ suma exactamente 1, ya que se reparte una probabilidad total de 1 entre sus $\text{out}(j)$ sucesores en partes iguales. Se verificó numéricamente que la suma de columnas de nodos no colgantes es 1.000000. Las columnas cero corresponden exactamente a los nodos colgantes (462 515, el 99.46 % del total), consistente con lo reportado en la Sección 3(b).

(b) Matriz columna-estocástica S

Cada columna cero de H se reemplaza por el vector uniforme $\mathbf{1}/n$, mediante

$$S = H + \frac{1}{n} \mathbf{a} \mathbf{1}^T,$$

donde $\mathbf{a}$ es el vector indicador de nodos colgantes. Por eficiencia, dado el tamaño de la red, S nunca se materializa como matriz densa: en su lugar, el producto $S\mathbf{r}$ se calcula “al vuelo” durante la iteración de potencias como $H\mathbf{r} + \frac{1}{n} \mathbf{a}(\mathbf{a}^T \mathbf{r})$, aprovechando que $\mathbf{1}^T \mathbf{r} = 1$ siempre ($\mathbf{r}$ es una distribución de probabilidad) y que $\mathbf{a}^T \mathbf{r}$ es simplemente un escalar. Se verificó que todas las columnas de S suman exactamente 1.

(c) Matriz de Google G

Se construye

$$G = \alpha S + \frac{1 - \alpha}{n} \mathbf{1} \mathbf{1}^T,$$

con $\alpha = 0.85$, el valor estándar propuesto originalmente por Brin y Page, que equilibra el peso de la estructura real de enlaces frente a la garantía teórica de convergencia y ergodicidad de la cadena de Markov asociada. Todas las entradas de G son estrictamente positivas porque el término de teletransportación $\frac{1-\alpha}{n} > 0$ se suma a cada entrada de $\alpha S \geq 0$, de modo que ninguna entrada de G puede ser cero; esto es precisamente lo que hace que G sea irreducible y aperiódica (ergódica), garantizando por el teorema de Perron-Frobenius un único vector propio positivo asociado al autovalor 1.

5. Cálculo del PageRank mediante iteración de potencias

Partiendo de $\mathbf{r}^{(0)} = \mathbf{1}/n$ y aplicando $\mathbf{r}^{(k+1)} = G\mathbf{r}^{(k)}$ mediante la descomposición dispersa descrita arriba, la iteración de potencias **convergió en solo 7 iteraciones**, alcanzando un error final $\|\mathbf{r}^{(k+1)} - \mathbf{r}^{(k)}\|_1 = 5.90 \times 10^{-12}$, por debajo de la tolerancia $\varepsilon = 10^{-10}$.

La curva de convergencia en escala logarítmica confirma un decaimiento geométrico del error, tal como predice la teoría: la razón de convergencia teórica de la iteración de potencias está acotada por $|\lambda_2|/|\lambda_1|$, donde λ_2 es el segundo autovalor de G en magnitud (siempre $|\lambda_2| \leq \alpha$). En este caso la razón de decaimiento observada resultó incluso más rápida que α (≈ 0.03 en promedio), lo que indica que el segundo autovalor efectivo de esta red particular es considerablemente menor que la cota superior $\alpha = 0.85$, probablemente debido a la enorme cantidad de nodos colgantes que refuerzan la mezcla rápida hacia la distribución uniforme.

Se verificó que $\|\mathbf{r}^*\|_1 = 1.0000000000$ y que $\min(\mathbf{r}^*) = 2.14 \times 10^{-6} > 0$ para todos los nodos. Ambas propiedades están garantizadas por la teoría: G es una matriz estocástica por columnas (cada columna suma 1), por lo que la iteración de potencias preserva la norma-1 del vector en cada paso; y G es estrictamente positiva (ergódica), por lo que el teorema de Perron-Frobenius garantiza un único autovector positivo asociado al autovalor dominante 1, normalizado para sumar 1.




Figure 2: Curva de convergencia (escala log) de la iteración de potencias.

6. PageRank vs. grado de entrada

Se calculó el coeficiente de correlación de Pearson entre el grado de entrada y el PageRank de todos los nodos de la red, obteniéndose un valor de $r = 0.6749$. Esta correlación es positiva y moderadamente fuerte, confirmando parcialmente la hipótesis inicial: los usuarios con más seguidores tienden en general a tener mayor PageRank, pero la relación dista de ser perfecta.

Se identificaron al menos dos casos que ilustran divergencias claras entre ambas métricas. El nodo **15161** tiene un in-degree alto de 97 (ranking #46 a nivel global por seguidores), pero su PageRank ocupa apenas el puesto #420 de 465 017, con un valor de 2.53×10^{-6} : sus seguidores son, en su mayoría, cuentas con bajo PageRank propio, por lo que su “voto” recursivo pesa poco. En el sentido opuesto, el nodo **400314** tiene solo 1 seguidor (in-degree = 1, ranking #400 338 a nivel global), pero su PageRank de 3.96×10^{-6} lo posiciona en el puesto #37 global: aparece precisamente en el subgrafo de los 40 nodos más influyentes (Figura 5), lo que indica que su único seguidor es, a su vez, un nodo con PageRank muy alto, y ese enlace “de calidad” pesa más que decenas de seguidores de bajo perfil.

7. Interpretación de resultados

Los usuarios con mayor PageRank (nodos 5486, 643 y 21275, con valores entre 5.47×10^{-6} y 5.82×10^{-6}) combinan, en general, un in-degree relativamente alto con conexiones desde otros nodos también bien posicionados. El caso más ilustrativo es el nodo 643: es el nodo con mayor grado de entrada de toda la red (199 seguidores) y también sigue a 479 usuarios, situándose en el segundo lugar del ranking de PageRank; su alta actividad de “seguir” hace que también reparta parte de su propio PageRank hacia otros nodos con los que interactúa, reforzando la estructura de la vecindad top-PageRank.

Otro patrón interesante es la aparición de nodos con in-degree muy bajo pero PageRank alto, como 52317 (in-degree = 8), 40468 (in-degree = 4) o 389105 (in-degree = 1). Estos casos muestran que PageRank no es un simple conteo de enlaces: basta con ser seguido por uno o pocos usuarios que a

Rango	Nodo (ID)	PageRank r_i^*	In-degree	Out-degree
1	5486	5.82e-06	174	0
2	643	5.75e-06	199	479
3	21275	5.47e-06	92	0
4	13847	4.60e-06	82	0
5	612	4.51e-06	144	0
6	5592	4.41e-06	124	183
7	1379	4.38e-06	161	0
8	1405	4.36e-06	174	0
9	3580	4.31e-06	127	491
10	5449	4.30e-06	133	0
11	1471	4.25e-06	153	0
12	52317	4.25e-06	8	0
13	7245	4.22e-06	111	0
14	2748	4.12e-06	151	0
15	40468	4.11e-06	4	0
16	731	4.10e-06	130	0
17	24463	4.08e-06	89	0
18	389105	4.04e-06	1	0
19	42961	4.01e-06	7	434
20	65942	4.00e-06	2	74

Table 4: Top-20 nodos con mayor PageRank.

su vez concentran mucho PageRank para heredar una fracción significativa de esa importancia, un efecto puramente recursivo que el grado de entrada por sí solo no puede capturar.

La visualización del subgrafo top-40 muestra una estructura mayoritariamente dispersa: casi todos los nodos top-PageRank aparecen aislados entre sí dentro de este subconjunto (solo se observa una arista entre los nodos 5592 y 5449), lo que es consistente con el hallazgo de la Sección 3(d): la red completa tiene una componente fuertemente conexas muy pequeña, y los usuarios más influyentes no necesariamente están directamente conectados entre ellos, sino que derivan su PageRank de la estructura completa de la red (incluyendo la teletransportación) y no de un núcleo denso de “élite” interconectada.

La red no incluye atributos adicionales de nodo (categoría temática, ubicación, etc.) en el archivo descargado de KONECT, por lo que no fue posible realizar un análisis de PageRank por grupos o comunidades etiquetadas; el análisis se limita a la estructura pura de seguidores.

8. Discusión, limitaciones y conclusiones

La hipótesis inicial se cumplió solo parcialmente: existe una correlación positiva y moderada (Pearson = 0.6749) entre in-degree y PageRank, confirmando que tener más seguidores ayuda a tener mayor PageRank. Sin embargo, tal como se anticipó, el efecto de los nodos colgantes (99.46 % de la red) comprime fuertemente las diferencias relativas: la mayoría de los valores de PageRank se concentran en un rango muy estrecho (entre $\sim 4 \times 10^{-6}$ y $\sim 6 \times 10^{-6}$ para el top-20), y aparecen casos claros —como el nodo 400314— donde un solo enlace de “calidad” desde un nodo influyente supera en PageRank a decenas de seguidores de bajo perfil, un resultado que no se anticipó con la misma claridad al inicio del proyecto.




Figure 3: Top-20 nodos por PageRank (barras), con detalle de in-degree y out-degree.

La pregunta planteada —si PageRank identifica un conjunto de usuarios influyentes distinto al que arrojaría un simple conteo de seguidores— quedó respondida afirmativamente: si bien hay una superposición considerable entre ambos rankings (Pearson ≈ 0.67), el análisis de la Sección 6 muestra ejemplos concretos y verificables de discrepancia en ambas direcciones.

En cuanto a las limitaciones del método para esta red en particular: el modelo de marcha aleatoria tiene sentido conceptual (un usuario “navega” siguiendo relaciones de seguimiento), pero la enorme proporción de nodos colgantes (99.46 %) hace que, en la práctica, casi toda la masa de probabilidad de la caminata dependa del salto uniforme por teletransportación y no de la estructura real de enlaces; esto se confirmó calculando que un 99.46 % de la masa total de PageRank corresponde a probabilidad “inyectada” a través de nodos colgantes. En consecuencia, la red es demasiado dispersa (densidad $\approx 3.86 \times 10^{-6}$) para que PageRank capture toda la riqueza estructural que tendría una red social más completa (donde se registrara también a quién sigue cada usuario, no solo quién es seguido). Además, el tope artificial de out-degree en 500 (repetido en decenas de nodos, Tabla 3) sugiere un límite impuesto por el crawler o la API usada para construir el dataset, y no un comportamiento orgánico de los usuarios, lo que le resta algo de interpretabilidad al modelo de marcha aleatoria.

Del análisis surgieron nuevas preguntas: ¿cómo cambiaría el ranking de PageRank si se filtraran previamente los nodos colgantes puros, dejando solo la subred de usuarios con actividad completa de *following*? ¿Qué tan sensible es el ranking top-20 a variaciones del parámetro α , dado el rol dominante de la teletransportación en esta red? ¿Los usuarios de mayor PageRank se concentran dentro de la componente fuertemente conexa más grande (apenas 0.37 % de la red), o están




Figure 4: PageRank vs. grado de entrada (escala log-log), con los nodos top-10/20 destacados en rojo.

mayoritariamente fuera de ella? Ambas preguntas podrían explorarse en un trabajo futuro.

Si tuviéramos que explicar el resultado principal a alguien sin conocimientos técnicos: PageRank no cuenta simplemente cuántos seguidores tiene una cuenta, sino que le da más “peso” a ser seguido por cuentas que a su vez son importantes. Es como una reputación que se hereda: no basta con tener muchos seguidores, importa también quiénes son esos seguidores. En esta red de Twitter, eso permitió detectar usuarios con pocos seguidores directos pero conectados a cuentas muy influyentes, que terminan siendo más relevantes de lo que su número de seguidores sugeriría a simple vista.

9. Reproducibilidad

Todo el código utilizado (descarga del dataset desde KONECT, construcción de $H/S/G$ en formato disperso, iteración de potencias, y generación de las figuras y tablas de este informe) se encuentra en el notebook `Twitter.ipynb` del repositorio del proyecto. El repositorio incluye instrucciones de ejecución y el enlace directo de descarga de los datos: http://konect.cc/files/download.tsv.munmun_twitter_social.tar.bz2.

Uso de inteligencia artificial

Se utilizaron herramientas de IA como apoyo durante el desarrollo del proyecto, principalmente para resolver dudas, revisar código y mejorar la redacción del informe.




Figure 5: Subgrafo inducido por los 40 nodos de mayor PageRank. Tamaño y color de los nodos según su PageRank; el grosor de las aristas refleja el PageRank del nodo de origen.